

ESTATÍSTICA APLICADA

Prof. Rita von Randow
rita.vonrandow@gmail.com

08/08/2024

a

15/08/2024



Agradecimento especial à professora Nanci de Oliveira por permitir que seu material seja utilizado no todo ou em partes durante este curso de Estatística.

MEDIDAS DE DISTRIBUIÇÃO DE FREQUÊNCIAS

A- Medidas de Tendência Central

- Média
- Mediana
- Moda

B- Medidas de Dispersão ou Variabilidade

- Desvio Médio
- Variância
- Desvio Padrão
- Coeficiente de variação: medida de dispersão relativa

C- Medidas de Posição

- Quartil
- Decil
- Percentil

As medidas de posição central tem por objetivo resumir e representar um conjunto de dados. As medidas de posição central mais utilizadas são: **moda**, **mediana** e **média**.

A- Medidas de Tendência Central

MÉDIA ARITMÉTICA

- É a mais usual das medidas estatísticas.
- É a soma dos valores de todos os dados dividido pelo número de dados

μ = Média da população

\bar{X} = média da amostra

$$\mu = \frac{\sum_{i=1}^n x}{N} \quad \text{ou} \quad \bar{x} = \frac{\sum_{i=1}^n x}{n}$$

ATENÇÃO:

Essas fórmulas somente serão usadas quando os dados **não estiverem agrupados em tabelas de distribuição de frequências.**



MEDIANA

- É o dado que fica na posição central de um conjunto de dados que estão em ordem crescente ou decrescente.

**Qual valor
está no
centro dos
dados
ordenados?**




Como encontrar a mediana?

Depois de ordenados os valores por ordem **crescente** ou decrescente, a **mediana** é:

- o valor que ocupa a posição central, se a quantidade desses valores for **ímpar**
- a média dos dois valores centrais, se a quantidade desses valores for **par**.

MODA

- É valor que mais se repete num conjunto de dados, ou seja, é o dado que ocorre com maior frequência.
- Se dois dados ocorrem com a mesma frequência elevada, cada dado é uma moda e os dados são chamados **bimodais**.
- Caso não haja dados repetidos, os dados são **amodais**.



EXEMPLO 1:

Média, Moda e Mediana

Gastos em eletricidade:

Esta tabela não é de distribuição de frequências.

Meses	JAN.	FEV.	MAR.	ABR.	MAI.
Gasto (em €)	25€	22€	35€	28€	35€



- Média: 29 €

$$\bar{x} = \frac{25 + 22 + 35 + 28 + 35}{5} = \frac{145}{5} = 29 \Rightarrow \bar{x} = 29$$

Moda: 35 €

Mediana: 28 €

Rol: 22 25 **28** 35 35

Número impar de dados 8

Agora é com vocês! Calculem a média, mediana e moda nesse exemplo

EXEMPLO 2:

Média, Moda e Mediana

Gastos em eletricidade:

Meses	JAN.	FEV.	MAR.	ABR.	MAI.	JUN.
Gastos (em €)	25€	22€	35€	28€	35€	33€



- Média: 29,67 €

$$\bar{x} = \frac{25 + 22 + 35 + 28 + 35 + 33}{6} = \frac{178}{6} = 29,67 \Rightarrow \bar{x} = 29,67$$

Moda: 35 €

Mediana: 30,5 €

Rol: 22 25 28 33 35 35

Número par de dados

$$\frac{28 + 33}{2} = \frac{61}{2} = 30,5$$

Média Ponderada

A média ponderada é utilizada quando cada valor de um conjunto de dados tem importâncias diferentes, isto é, aquelas com a maior importância (maior peso) devem influenciar mais na média. A média ponderada é:

$$\bar{x}_G = \sum_{i=1}^k x_i \times p_i$$

Onde p_i é o peso com as seguintes condições:

$$0 < p_i < 1 \text{ e } \sum_{i=1}^k p_i = 1$$

MÉDIA DE DADOS AGRUPADOS

- A **média de uma distribuição de frequências** para uma amostra é dada por:

ATENÇÃO:

Esta fórmula é usada quando os dados estão agrupados em tabelas de distribuição de frequências.

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} \quad \text{onde} \quad n = \sum_{i=1}^n f_i$$

$X_i = Pm_i =$ variável ou ponto médio da classe i
 $f_i =$ frequência da classe i

EXEMPLO 1

MÉDIA PARA DADOS AGRUPADOS

Use a distribuição de frequências abaixo para calcular a média do número de minutos que uma amostra de internautas gastou durante sua navegação mais recente na rede.

x_i	f_i
12,5	6
24,5	10
36,5	13
48,5	8
60,5	5
72,5	6
84,5	2
	$\Sigma f_i = 50$

Como os dados estão agrupados em uma distribuição de frequências, temos que usar a seguinte fórmula:

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} \quad \text{onde} \quad n = \sum_{i=1}^n f_i$$

Solução

X_i	f_i	$X_i \cdot f_i$
12,5	6	75,0
24,5	10	245,0
36,5	13	474,5
48,5	8	388,0
60,5	5	302,5
72,5	6	435,0
84,5	2	169,0
	$\Sigma f_i = 50$	$\Sigma X_i \cdot f_i = 2089,0$

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} = \frac{2089}{50} = 41,8$$

Logo, $\bar{x} = 41,8$ minutos.

EXEMPLO 2

MÉDIA PARA DADOS AGRUPADOS

Use a distribuição de frequências abaixo para calcular a média dos estaturas, em cm, de 50 atletas.

Estaturas	f_i
150 — 155	2
155 — 160	10
160 — 165	12
165 — 170	15
170 — 175	5
175 — 180	6
	$\Sigma f_i = 50$

*Como os dados estão agrupados em uma distribuição de frequências, temos que usar a seguinte fórmula, porém, inicialmente, temos que encontrar os **pontos médios de cada classe** X_i :*

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} \quad \text{onde} \quad n = \sum_{i=1}^n f_i$$

EXEMPLO 2

MÉDIA PARA DADOS AGRUPADOS

Use a distribuição de frequências abaixo para calcular a média dos estaturas, em cm, de 50 atletas.

Estaturas	X_i	f_i
150 — 155	152,5	2
155 — 160	157,5	10
160 — 165	162,5	12
165 — 170	167,5	15
170 — 175	172,5	5
175 — 180	177,5	6
		$\Sigma f_i = 50$

*Como os dados estão agrupados em uma distribuição de frequências, temos que usar a seguinte fórmula, porém, inicialmente, temos que encontrar os **pontos médios de cada classe X_i** :*

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} \quad \text{onde} \quad n = \sum_{i=1}^n f_i$$

Solução

<i>Estaturas</i>	X_i	f_i	$X_i \cdot f_i$
150 — 155	152,5	2	305
155 — 160	157,5	10	1575
160 — 165	162,5	12	1950
165 — 170	167,5	15	2512,5
170 — 175	172,5	5	862,5
175 — 180	177,5	6	1065
		$\Sigma f_i = 50$	$\Sigma X_i \cdot f_i = 8270$

$$\bar{x} = \frac{\sum_{i=1}^n x_i f_i}{n} = \frac{8270}{50} = 165,4$$

Logo, $\bar{x} = 165,4 \text{ cm}$.

MEDIDAS DE DISTRIBUIÇÃO DE FREQUÊNCIAS

B- Medidas de Dispersão ou Variabilidade

- Amplitude Total
- Desvio Médio
- Variância
- Desvio Padrão
- Coeficiente de variação

MEDIDAS DE DISPERSÃO

- **Numa pesquisa, os dados coletados podem:**
 - assumir valores diferentes entre si
 - situar-se próximos ou não de uma medida de tendência central, como a média aritmética
 - situar-se próximos entre si ou não
 - ser discrepantes, em alguns casos
- **Medidas de dispersão visam atribuir um valor numérico, da melhor forma possível, que expresse a homogeneidade ou não entre os diversos valores obtidos numa pesquisa.**

AMPLITUDE TOTAL

- A **amplitude total** de um conjunto de dados é a diferença entre o valor máximo e o valor mínimo assumido pela variável.

$$AT = (X_{máx} - X_{mín}) \text{ do rol}$$

onde ***X*** é a variável.

DESVIO

- O **desvio** de um conjunto de dados é a diferença entre os valores da variável e a média do conjunto de dados, podendo ser para mais (+) ou para menos (-).

$$d_i = X_i - \bar{X}$$

EXEMPLO - DESVIO

A empresa A contratou dez pessoas com curso superior. O salário inicial nessa companhia é mostrado a seguir.

- Salário inicial na empresa A (em milhares de dólares)

Salário	37	38	39	41	41	41	42	44	45	47
---------	----	----	----	----	----	----	----	----	----	----

- Determine o desvio de cada salário inicial para a empresa A.

Salário (milhares de dólares) X_i	Desvio (milhares de dólares) $X - \bar{X}_i$
37	-4,5
38	-3,5
39	-2,5
41	-0,5
41	-0,5
41	-0,5
42	0,5
44	2,5
45	3,5
47	5,5
$\Sigma X_i = 415$	$\Sigma (X_i - \bar{X}) = 0$

O salário médio inicial da empresa é

$$\bar{X} = \frac{\sum X_i}{n}$$

$$\bar{X} = \frac{415}{10} = 41,5$$

$$\bar{X} = 41,5$$

Observe que a soma dos desvios é zero. Isso ocorre para todo conjunto de dados. Se calcularmos a média dos desvios, obteremos sempre zero.

DESVIO MÉDIO

- Para resolver o problema anterior (média dos desvios igual a zero), calculamos o módulo dos desvios. Obtemos assim o **desvio médio**.

$$DM = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

EXEMPLO - DESVIO MÉDIO

Salário (milhares de dólares) x_i	Módulo do Desvio (milhares de dólares) $ x_i - \bar{x} $
37	$ -4,5 = 4,5$
38	$ -3,5 = 3,5$
39	$ -2,5 = 2,5$
41	$ -0,5 = 0,5$
41	$ -0,5 = 0,5$
41	$ -0,5 = 0,5$
42	$ 0,5 = 0,5$
44	$ 2,5 = 2,5$
45	$ 3,5 = 3,5$
47	$ 5,5 = 5,5$
$\Sigma x_i = 415$	$\Sigma x_i - \bar{x} = 24$

O desvio médio do salário inicial da empresa A é:

$$DM = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

$$DM = \frac{24}{10} = 2,4 \text{ mil dólares}$$

VARIÂNCIA

- Dispensa o uso do MÓDULO.
- Usa os desvios ao quadrado.
- Em um conjunto de dados, a média dos quadrados dos desvios é chamada de **variância**.

VARIÂNCIA AMOSTRAL

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

- Para a **variância populacional** utilizamos:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{N}$$

DESVIO PADRÃO

- Resolve o problema dimensional da variância.
- **Desvio padrão** é a raiz quadrada da variância.

DESVIO PADRÃO AMOSTRAL

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

- Para o **desvio padrão populacional** utilizamos:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{N}}$$

EXEMPLO

VARIÂNCIA E DESVIO PADRÃO

Obtenha a variância e o desvio padrão amostrais do salário inicial para a empresa A.

- Salário inicial na empresa A (em milhares de dólares)

Salário	37	38	39	41	41	41	42	44	45	47
---------	----	----	----	----	----	----	----	----	----	----

Salário (milhares de dólares) X_i	Desvio ao quadrado (milhares de dólares) $(X_i - \bar{X})^2$
37	$(37-41,5)^2 = (-4,5)^2 = 20,25$
38	$(38-41,5)^2 = (-3,5)^2 = 12,25$
39	$(39-41,5)^2 = (-2,5)^2 = 6,25$
41	$(41-41,5)^2 = (-0,5)^2 = 0,25$
41	$(41-41,5)^2 = (-0,5)^2 = 0,25$
41	$(41-41,5)^2 = (-0,5)^2 = 0,25$
42	$(42-41,5)^2 = (0,5)^2 = 0,25$
44	$(44-41,5)^2 = (2,5)^2 = 6,25$
45	$(45-41,5)^2 = (3,5)^2 = 12,25$
47	$(47-41,5)^2 = (5,5)^2 = 30,25$
$\Sigma X_i = 415$	$\Sigma (X_i - \bar{X})^2 = 88,5$

$$\bar{X} = \frac{\Sigma X_i}{n} = \frac{415}{10} = 41,5$$

Variância amostral:

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$$

$$S^2 = \frac{88,5}{10-1} = \frac{88,5}{9} = 9,83$$

$$s^2 = 9,83 \text{ mil dólares}$$

Desvio padrão amostral:

$$s = \sqrt{9,83} \approx 3,14$$

$$s = 3,14 \text{ mil dólares}$$

MEDIDA DE DISPERSÃO RELATIVA

- As medidas de dispersão que vimos anteriormente (amplitude total, desvio médio, variância e desvio padrão) somente são comparáveis quando se referem a mesma escala de medida e quando os grupos têm média não muito diferentes.
- **Para avaliar a variação dos dados de pesquisa através de um número índice (porcentagem), utilizamos o coeficiente de variação.**

COEFICIENTE DE VARIAÇÃO

- **Coeficiente de variação (C.V.)** é a razão entre o desvio padrão e a média, multiplicada por 100. Portanto, ele é dado **em porcentagem**.

$$C.V. = \frac{s}{\bar{X}} \cdot 100 (\%)$$

EXEMPLO

COEFICIENTE DE VARIAÇÃO

Compare a variação das idades dos 2 grupos seguintes.

1º grupo - Idade, em anos, de três crianças: 1, 3, 5

2º grupo- Idade, em anos, de três adultos: 53, 55, 57

Cálculo da média aritmética dos dois grupos:

1º grupo

$$\bar{X} = \frac{1+3+5}{3} = \frac{9}{3} = 3 \text{ anos}$$

2º grupo

$$\bar{X} = \frac{53+55+57}{3} = \frac{165}{3} = 55 \text{ anos}$$

Cálculo do desvio padrão (dispersão absoluta) dos dois grupos:

1º grupo

X_i	$(X_i - \bar{X})^2$
1	$(1 - 3)^2 = 4$
3	$(3 - 3)^2 = 0$
5	$(5 - 3)^2 = 4$
	$\sum (X - \bar{X})^2 = 8$

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{8}{2} = 4$$

$$s = \sqrt{4} = 2 \text{ anos}$$

2º grupo

X_i	$(X_i - \bar{X})^2$
53	$(53 - 55)^2 = 4$
55	$(55 - 55)^2 = 0$
57	$(57 - 55)^2 = 4$
	$\sum (X - \bar{X})^2 = 8$

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{8}{2} = 4$$

$$s = \sqrt{4} = 2 \text{ anos}$$

A dispersão dos dados em torno da média é exatamente a mesma ($s = 2$ anos), porém, a diferença de 2 anos no 1º grupo é bastante significativo na mudança física, já no 2º grupo não o é.

Cálculo do coeficiente de variação (dispersão relativa) dos dois grupos:

1o grupo:

$$C.V. = \frac{s}{\bar{X}} \cdot 100 (\%)$$

$$C.V. = \frac{2}{3} \cdot 100 = 66,7\%$$

2o grupo:

$$C.V. = \frac{s}{\bar{X}} \cdot 100 (\%)$$

$$C.V. = \frac{2}{55} \cdot 100 = 3,64\%$$

Como o coeficiente de variação foi maior no 1º grupo, concluímos que o 1º grupo teve maior variação nos seus dados.

DESVIO PADRÃO PARA DADOS AGRUPADOS

- A fórmula para o desvio padrão da amostra de uma distribuição de frequência é:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{n - 1}}$$

onde $n = \sum f_i$ é o número total de dados.

EXEMPLO 1- DESVIO PADRÃO PARA DADOS AGRUPADOS EM DISTRIBUIÇÃO DE FREQUÊNCIAS

Os resultados de uma amostra do número de crianças por família em uma região estão dispostos na tabela abaixo. Determine a média e o desvio padrão.

x_i	f_i
0	10
1	19
2	7
3	7
4	2
5	1
6	4
	$\Sigma f_i = 50$

número de crianças por família

número de famílias

X_i	f_i	$X_i \cdot f_i$	$(X_i - \bar{X})^2 \cdot f_i$
0	10	0	$(0 - 1,8)^2 \cdot 10 = (3,24) \cdot 10 = 32,4$
1	19	19	$(1 - 1,8)^2 \cdot 19 = (0,64) \cdot 19 = 12,16$
2	7	14	$(2 - 1,8)^2 \cdot 7 = (0,04) \cdot 7 = 0,28$
3	7	21	$(3 - 1,8)^2 \cdot 7 = (1,44) \cdot 7 = 10,08$
4	2	8	$(4 - 1,8)^2 \cdot 2 = (4,84) \cdot 2 = 9,68$
5	1	5	$(5 - 1,8)^2 \cdot 1 = (10,24) \cdot 1 = 10,24$
6	4	24	$(6 - 1,8)^2 \cdot 4 = (17,64) \cdot 4 = 70,56$
	$\Sigma f_i = 50$	$\Sigma X_i \cdot f_i = 91$	$\Sigma (X_i - \bar{X})^2 f_i = 145,40$

Média: $\bar{X} = \frac{\Sigma X_i \cdot f_i}{\Sigma f_i} = \frac{91}{50} = 1,8 \text{ crianças}$

Desvio padrão: $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{n - 1}} = \sqrt{\frac{145,4}{49}} = \sqrt{2,967} = 1,7 \text{ crianças}$

Agora é com vocês! Calculem o desvio padrão para o exemplo abaixo

EXEMPLO 2- DESVIO PADRÃO PARA DADOS AGRUPADOS EM DISTRIBUIÇÃO DE FREQUÊNCIAS

O resultado de uma sondagem na qual mil adultos foram indagados sobre quanto gastavam anualmente na preparação de uma viagem de férias resultou na distribuição de frequência abaixo. Estime a média e o desvio padrão amostrais do conjunto de dados.

<i>Gastos (US\$)</i>	<i>f_i</i>
0 — 100	380
100 — 200	230
200 — 300	210
300 — 400	50
400 — 500	60
500 — 600	70
	$\Sigma f_i = 1000$

Gastos (US\$)	f_i	X_i	$X_i \cdot f_i$	$(X_i - \bar{X})^2 f_i$
0 — 100	380	50	19.000	$(50 - 189)^2 \cdot 380 = 7.341.980$
100 — 200	230	150	34.500	$(150 - 189)^2 \cdot 230 = 349.830$
200 — 300	210	250	52.500	$(250 - 189)^2 \cdot 210 = 781.410$
300 — 400	50	350	17.500	$(350 - 189)^2 \cdot 50 = 1.296.050$
400 — 500	60	450	27.000	$(450 - 189)^2 \cdot 60 = 4.087.260$
500 — 600	70	550	38.500	$(550 - 189)^2 \cdot 70 = 9.122.470$
	$\Sigma f_i = 1000$		$\Sigma X_i \cdot f_i = 189.000$	$\Sigma (X_i - \bar{X})^2 f_i = 22.979.000$

Média: $\bar{X} = \frac{\Sigma X_i \cdot f_i}{\Sigma f_i} = \frac{189000}{1000} = \mathbf{189 \text{ dólares}}$

Desvio padrão:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{n - 1}} = \sqrt{\frac{22979000}{999}} = \sqrt{23002,002} = \mathbf{151,66 \text{ dólares}}$$

FÓRMULAS

MEDIDAS DE DISPERSÃO

- As fórmulas seguintes são usadas para dados agrupados em distribuição de frequências.

Variância Amostral	$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{n - 1}$
Desvio Padrão Amostral	$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{n - 1}}$



MEDIDAS DE POSIÇÃO

C- Medidas de Posição

- Quartil
- Decil
- Percentil

QUARTIS

- **Quartis** são números que dividem aproximadamente um conjunto ordenado de dados em **quatro partes iguais**.
- Portanto, há 3 quartis: **Q_1** , **Q_2** e **Q_3** .
- Cerca de $\frac{1}{4}$ dos dados é menor ou igual ao 1º quartil.
- Cerca de $\frac{1}{2}$ (metade) dos dados é menor ou igual ao 2º quartil. O 2º quartil é igual à mediana do conjunto de dados.
- Cerca de $\frac{3}{4}$ dos dados é menor ou igual ao 3º quartil.

QUARTIS

Ou seja, cada parte deve ter 25% dos dados.

→→ Primeiro quartil é o valor onde 25% dos dados são menores ou iguais a ele, conseqüentemente 75% são maiores ou iguais a ele;

→→ Segundo quartil (mediana) é o valor onde 50% dos dados são menores ou iguais a ele e, 50% são maiores ou iguais a a ele;

→→ Terceiro quartil é é o valor onde 75% dos dados são menores ou iguais a ele, 25% são maiores ou iguais a ele.

O segundo quartil coincide com a mediana, portanto, é pouco utilizado.


EXEMPLO - QUARTIS

A pontuação nos testes de 15 empregados envolvidos em um curso de treinamento está disposta a seguir. Obtenha os 3 quartis da pontuação dos testes.

13	9	18	15	14	21	7	10	11	20	5	18	37	16	17
----	---	----	----	----	----	---	----	----	----	---	----	----	----	----

Em 1º lugar, ordene o conjunto de dados e obtenha a mediana, que é igual ao 2º quartil.

Uma vez obtido o 2º quartil, pode-se dividir o conjunto de dados em 2 metades. O 1º e o 3º quartis são as medianas das metades inferior e superior do conjunto de dados.



Assim, cerca de $\frac{1}{4}$ dos empregados fez dez pontos ou menos, cerca da metade fez 15 pontos ou menos e cerca de $\frac{3}{4}$ conseguiu 18 pontos ou menos.

QUARTIS

No cálculo do quartil, deve-se primeiramente calcular a posição onde ele se encontra e, depois calculá-lo através de uma média ponderada de dois valores, caso seja necessário. O quartil pode ser obtida através de:

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)}$$

Com $i = 1, 2$ e 3 para se obter Q_1, Q_2 e Q_3 para um conjunto com n dados. O uso da média ponderada de dois valores é aplicado quando o resultado da posição $\left(\frac{i \times n}{4} + \frac{1}{2}\right)$ não é inteiro.

EXEMPLO 1

Para um conjunto com $n = 10$:

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
9	10	12	14	16	17	17	19	20	22

O primeiro quartil e o terceiro quartil são:

$$Q_1 = x_{\left(\frac{1 \times 10}{4} + \frac{1}{2}\right)} = x_{(3)} = 12$$

e

$$Q_3 = x_{\left(\frac{3 \times 10}{4} + \frac{1}{2}\right)} = x_{(8)} = 19$$

Como as posições do primeiro quartil e terceiro quartil deram números inteiros, os quartis são associados à posição no conjunto ordenado de dados.

EXEMPLO 2

Para um conjunto com $n = 11$ tem-se:

x_1	x_2	x_3		x_4	x_5	x_6	x_7	x_8		x_9	x_{10}	x_{11}
9	10	12		14	16	17	17	19		20	22	24

O primeiro quartil é:

$$Q_1 = x_{\left(\frac{1 \times 11}{4} + \frac{1}{2}\right)} = x_{(3,25)}$$

Nesse caso, a “posição” 3,25 (número não inteiro) indica que o primeiro quartil está entre o terceiro e o quarto valor e, as casas decimais, 0,25, são interpretadas como proximidade maior ao terceiro do que o quarto elemento. As casas decimais também serão utilizadas como peso no cálculo do Q_1 e, quanto maior a proximidade maior será o peso para o cálculo de Q_1 . A média ponderada entre x_3 e x_4 tem pesos iguais a $(1-0,25)$ para x_3 e $(0,25)$ para o x_4 , respectivamente.

O procedimento para a obtenção dos quartis é inicialmente calcular:

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)} = x_{(j,d)}$$

Representando o resultado por $x_{(j,d)}$ com j o número inteiro e d a casa decimal da expressão, o quartil é dado por:

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)} = x_{(j,d)} = (1-d) \times x_{(j)} + (d) \times x_{(j+1)}$$

Para $i=1, 2$ e 3 .

Assim, o primeiro quartil será:

$$Q_1 = x_{\left(\frac{1 \times 11}{4} + \frac{1}{2}\right)} = x_{(3,25)}$$

Nesse caso, o primeiro quartil está entre o terceiro e o quarto valor e a casa decimal (0,25), indica que está mais próximo do terceiro elemento.

O primeiro quartil é:

$$\begin{aligned} Q_1 &= x_{\left(\frac{1 \times 11}{4} + \frac{1}{2}\right)} = x_{(3,25)} = (1 - 0,25) \times x_3 + (0,25) \times x_4 \\ &= (1 - 0,25) \times 12 + (0,25) \times 14 = 12,5 \end{aligned}$$

Assim, o terceiro quartil será:

$$Q_3 = x_{\left(\frac{3 \times 11}{4} + \frac{1}{2}\right)} = x_{(8,75)}$$

Nesse caso, o terceiro quartil está entre o oitavo e o nono valor e a casa decimal (0,75), indica que está mais próximo do nono elemento.

O terceiro quartil é:

$$\begin{aligned} Q_3 &= x_{\left(\frac{3 \times 11}{4} + \frac{1}{2}\right)} = x_{(8,75)} = (1 - 0,75) \times x_8 + (0,75) \times x_9 \\ &= (1 - 0,75) \times 19 + (0,75) \times 20 \\ &= 19,75 \end{aligned}$$

Exercício:

Calcule o primeiro, segundo e terceiro quartis do seguinte conjunto:

17

20

22

27

9

12

14

17

19

24

10

16

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)}$$

Resposta: Q1 = 13; Q2 = 17 e Q3 = 21

Exercício:

Calcule o primeiro, segundo e terceiro quartis do seguinte conjunto:

17
20
22
27
9
12
14
17
19
24
10
16

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)} = x_{(j,d)}$$

$$Q_i = x_{\left(\frac{i \times n}{4} + \frac{1}{2}\right)} = x_{(j,d)} = (1-d) \times x_{(j)} + (d) \times x_{(j+1)}$$

Para $i = 1, 2$ e 3 .

9 10 12 | 14 16 17 | 17 19 20 | 22 24 27
 Q1=13 Q2=17 Q3=21

Resposta: $Q1 = 13$; $Q2 = 17$ e $Q3 = 21$

DECIS E PERCENTIS

- **DECIS** dividem o conjunto de dados em 10 partes iguais. São 9 decis: **D₁**, **D₂**, **D₃**, ... **D₉**
- **PERCENTIS** dividem o conjunto de dados em 100 partes iguais. São 99 percentis: **P₁**, **P₂**, **P₃**, ... **P₉₉**
- Os **percentis** são frequentemente usados na Educação e nos campos relacionados à Saúde para indicar como um indivíduo se compara com os outros em um determinado grupo. Pontuações em testes e medidas de crescimento infantil, por exemplo, são frequentemente expressos em percentis.

Desta forma, os **Decis** são calculados da seguinte forma:

$$D_i = x_{\left(\frac{i \times n}{10} + \frac{1}{2}\right)}$$

Com i variando de 1 até 9.

O cálculo é feito como o dos quartis e o resultado pode ser representado por $x_{(j,d)}$, com j a parte inteira e d a parte das casas decimais.

O cálculo dos decis é dado por:

$$D_i = x_{\left(\frac{i \times n}{10} + \frac{1}{2}\right)} = x_{(j,d)} = (1-d) \times x_{(j)} + (d) \times x_{(j+1)}$$

para $i = 1, 2, \dots, 9$.

Agora com vocês!

Calcule **o primeiro decil, o segundo decil e o nono decil** do conjunto ordenado de 20 números dado a seguir:

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	x_{12}	x_{13}	x_{14}	x_{15}	x_{16}	x_{17}	x_{18}	x_{19}	x_{20}
9	10	12	14	16	17	17	19	20	22	24	27	30	31	32	34	35	37	38	39

$$D_i = x_{\left(\frac{i \times n}{10} + \frac{1}{2}\right)} = x_{(j,d)} = (1-d) \times x_{(j)} + (d) \times x_{(j+1)}$$

para $i = 1, 2, \dots, 9$.

$$\begin{aligned}
 D_1 &= x_{\left(\frac{1 \times 20}{10} + \frac{1}{2}\right)} = x_{(2,5)} = (1 - 0,5) \times x_{(2)} + (0,5) \times x_{(3)} \\
 &= (1 - 0,5) \times 10 + (0,5) \times 12 \\
 &= 11
 \end{aligned}$$

Interpretação: 10% dos dados são menores ou iguais a 11 ou 90% são maiores ou iguais a 11.

$$\begin{aligned}
 D_2 &= x_{\left(\frac{2 \times 20}{10} + \frac{1}{2}\right)} = x_{(4,5)} = (1 - 0,5) \times x_{(4)} + (0,5) \times x_{(5)} \\
 &= (1 - 0,5) \times 14 + (0,5) \times 16
 \end{aligned}$$

Interpretação: 20% dos dados são menores ou iguais a 15 ou 80% são maiores ou iguais a 15.

$$\begin{aligned}
 D_9 &= x_{\left(\frac{9 \times 20}{10} + \frac{1}{2}\right)} = x_{(18,5)} = (1 - 0,5) \times x_{(18)} + (0,5) \times x_{(19)} \\
 &= (1 - 0,5) \times 37 + (0,5) \times 38 \\
 &= 37,5
 \end{aligned}$$

Interpretação: 90% dos dados são menores ou iguais a 37,5 ou 10% são maiores ou iguais a 37,5.

Como são calculados os **Percentis**?

$$P_i = x_{\left(\frac{i \times n}{100} + \frac{1}{2}\right)}$$

Com i variando de 1 até 99 para obter P_1, P_2, \dots, P_{99} .

Exemplo: Calcule o P_5 , P_{95} da série ordenada a seguir:

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
9	10	12	14	16	17	17	19	20	22
x_{11}	x_{12}	x_{13}	x_{14}	x_{15}	x_{16}	x_{17}	x_{18}	x_{19}	x_{20}
24	27	30	31	32	34	35	37	38	39

Resposta: $P_5 = 9,5$ e $P_{95} = 38,5$

APLICAÇÃO

Claudia é gerente de Marketing da empresa **Calça & Moda**. Ela gostaria de saber se a promoção de desconto na compra da segunda peça aumentou o gasto por cliente. Para isso, ela analisou no banco de dados o gasto de 20 clientes antes da promoção e, o gasto de 16 clientes durante a promoção. Os gastos observados são:



GASTOS ANTES DA PROMOÇÃO
(em reais)

141	117	129	115
113	69	133	96
86	168	63	151
104	104	59	115
90	138	131	84



GASTOS DURANTE A PROMOÇÃO
(em reais)

108	88	110	79
112	90	123	97
125	130	102	140
158	108	129	119

A gerente gostaria de saber o valor da compra dos 10% e 25% dos menores gastos e também dos 5% e 25% dos maiores gastos por compra.

Outra informação é a média dos gastos e a mediana dos gastos antes e durante a promoção.

Em termos de Quartis, Decis e Percentis. O que vocês deverão calcular?

As medidas de ordenamento desejadas pela Claudia são:

$P_{10} = D_1$: o valor dos 10% que menos gastam por compra;

$P_{25} = Q_1$: o valor dos 25% que menos gastam por compra;

P_{95} : o valor dos 5% que mais gastam por compra;

$P_{75} = Q_3$: o valor dos 25% que mais gastam por compra.


Além da média e mediana de gastos antes e durante a promoção.

Os resultados obtidos foram:

	ANTES DA PROMOÇÃO	DURANTE A PROMOÇÃO
D_1	66	88,2
Q_1	88	99,5
Md	114	111
Q_3	132	127
P_{95}	159,5	152,6
média	110,3	113,63

APLICAÇÃO DOS QUARTIS: BOX PLOT

- Uma aplicação importante dos quartis é o **box plot**, também conhecidos como **plotes maria-chiquinha**, que é uma maneira de representar os dados.
- **BOX PLOT** é um **gráfico de dispersão** que relaciona os valores de uma variável com medidas estatísticas.



RESUMO CINCO-NÚMEROS DOS DADOS

- Para fazer um box plot é preciso conhecer os seguintes valores:




- Esses 5 valores são chamados de **resumo cinco-números** do conjunto de dados.

COMO FAZER UM BOX PLOT ?

1. Obtenha o resumo cinco-números do conjunto de dados
2. Construa uma escala horizontal que abranja a amplitude total dos dados.
3. Plote os cinco números acima da escala horizontal.
4. Faça uma caixa acima da escala horizontal de Q1 a Q3 e trace uma reta vertical na caixa, passando por Q2.
5. Faça as “tranças” a partir da cabeça para o menor valor e o maior valor.


MODELO DE BOX PLOT


- Círculos, bem como quadradinhos indicam valores em uma pesquisa pelos quais diferem de grandeza dos demais, isto é, são dados distorcidos.



EXEMPLO - BOX PLOT

Faça um Box Plot que represente a pontuação dos 15 testes dados... (exemplo dos quartis).
O que você pode concluir a partir do gráfico?






O **resumo cinco-números** das pontuações no teste são:

Menor valor = 5 $Q_1 = 10$ $Q_2 = 15$ $Q_3 = 18$ Maior valor = 37

BOX PLOT

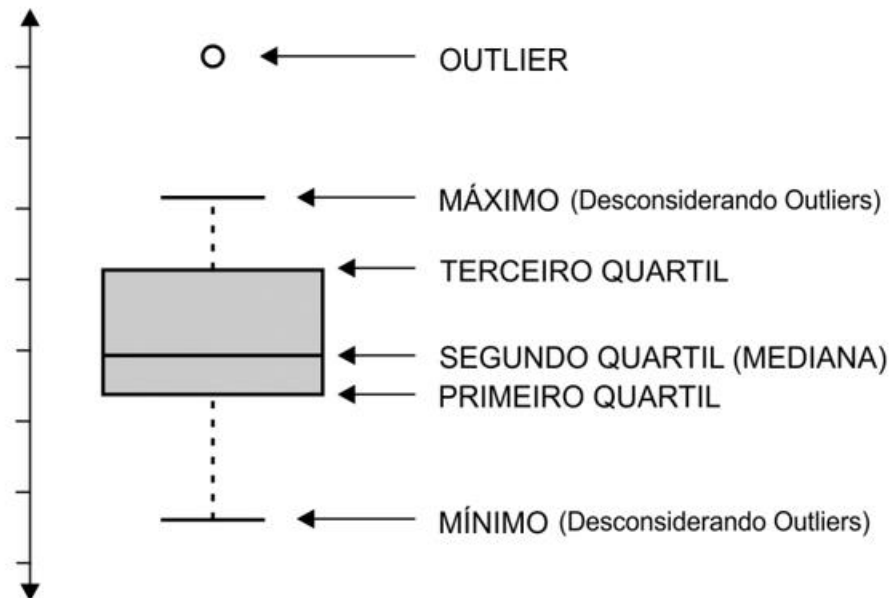


Uma das conclusões: cerca de metade das pontuações está entre 10 e 18.

Se eu tenho outliers no Boxplot

O limite de detecção de outliers é construído utilizando o intervalo interquartílico, dado pela distância entre o primeiro e o terceiro quartil. Sendo assim, os limites inferior e superior de detecção de outlier são dados por:

- Limite Inferior = Primeiro Quartil – $1,5 * (\text{Terceiro Quartil} - \text{Primeiro Quartil})$
- Limite Superior = Terceiro Quartil + $1,5 * (\text{Terceiro Quartil} - \text{Primeiro Quartil})$



Dados Agrupados em Intervalos

Quando os dados já estiverem agrupados em intervalos (na forma de tabela de frequência) e os dados brutos não são disponíveis para o cálculo exato das medidas de ordenamento, devemos obter essas medidas através de aproximações. Adota-se um procedimento para o cálculo do percentil que valerá para o cálculo do quartil e decil, pois essas medidas são casos particulares dos percentil.

Supondo o cálculo de P_i , com $i = 1, 2, 3, \dots, 99$. O primeiro passo é calcular:

$$\left(\frac{i \times n}{100} \right)$$

que identifica a posição onde se encontra o percentil em questão e, depois calcular as frequências acumuladas.

O primeiro valor da frequência acumulada que ultrapassar ou igualar ao $\left(\frac{i \times n}{100}\right)$ é o intervalo que contém o P_i e, depois utilizar a fórmula de P_i dado a seguir. Essa expressão é obtida por relação de proporcionalidade (regra de três).

$$P_i = \text{LimInf} + h \times \frac{\frac{i \times n}{100} - F_{\text{acumulada anterior}}}{f_{\text{classe do } i}}$$

Onde:

- **LimInf:** é o limite inferior do intervalo que contém o percentil i ;
- **h:** é o tamanho do intervalo que contém o percentil i ;
- **n:** é o tamanho da amostra;
- **$F_{\text{acumulada anterior}}$:** é a frequência acumulada anterior ao intervalo que contém o percentil i ;
- **$f_{\text{classe do } i}$:** é a frequência do intervalo que contém o percentil i .

Exemplo:

Utilizando a tabela de frequência a seguir calcule o P_{10} como exemplo.

CLASSE			FREQUÊNCIA	FREQUÊNCIA ACUMULADA
LIMITE INFERIOR		LIMITE SUPERIOR		
10	└	15	5	5
15	└	20	12	17
20	└	25	8	25
25	└	30	3	28
total (n)			28	

Para achar a posição do P_{10} , 1º calculo $\left(\frac{i \times n}{100}\right)$

$$i = 10 \text{ e } n = 28 \Rightarrow \left(\frac{10 \times 28}{100}\right) = 2,8$$

$\therefore P_{10}$ está na 1ª classe, de frequência acumulada de 0 a 5

Exemplo:

Utilizando a tabela de frequência a seguir calcule o P_{10} como exemplo.

CLASSE			FREQUÊNCIA
LIMITE INFERIOR		LIMITE SUPERIOR	
10	└	15	5
15	└	20	12
20	└	25	8
25	└	30	3
total (n)			28

LimInf = 10		CLASSE			FREQUÊNCIA ACUMULADA		$f_{\text{acumulada anterior}} = 0$ intervalo do P_{10}
LIMITE INFERIOR		LIMITE SUPERIOR		FREQUÊNCIA			
10	└	15		5		5	
15	└	20		12		17	
20	└	25		8		25	
25	└	30		3		28	
		total (n)		28			
$h = 15 - 10 = 5$					$f_{10 \text{ percentil}} = 5$		

Nesse caso, o P_{10} será:

$$P_i = \textit{LimInf} + h \times \frac{\frac{i \times n}{100} - F_{\text{acumulada anterior}}}{f_{\text{classe do i}}}$$

$$= 10 + 5 \times \frac{\frac{10 \times 28}{100} - 0}{5}$$

$$= 12,8$$

Obs.: Se P_i está contido no primeiro intervalo a frequência acumulada anterior será igual a zero.

Exercício:

Em um escritório, o tempo por dia (em minutos), no horário de trabalho, que a Internet na área que João trabalha fica fora do ar em virtude de uma falha da prestadora de serviços, está apresentado na distribuição seguir.

Tempo parado em minutos	0 – 10	10 – 20	20 – 30	30 -- 40	40 – 50	Total
Fi	2	15	17	13	3	50

a) Calcule a média, moda e mediana.

b) Calcule o Q3, D3, P63.

Referências

SANTIAGO, M. S.; AKAMINE, C. T.; MORSELLI, N. V. Estatística Aplicada à Gestão. UNIVESP. São Paulo, 2016.